1 L2正则化

1.1 L范数

- 距离度量

  在 n 维实数向量空间 $\mathbf{R}^n$ 中。使用的距离度量是的 L_p 距离（L_p distance）或 Minkowski 距离 (Minkowski distance)，又称为 L_p 范数,其中 L_2 范数又称为欧几里得范数。

  设特征空间 $\mathcal{X}$ 是 n 维实数向量空间 $\mathrm{R}^n, x_i, x_j \in \mathcal{X}, x_i=\left(x_i^{(1)}, x_i^{(2)}, \cdots, x_i^{(n)}\right)^{\mathrm{T}}$, $x_j=\left(x_j^{(1)}, x_j^{(2)}, \cdots, x_j^{(n)}\right)^{\mathrm{T}}, x_i, x_j$ 的 L_p 距离定义为

$$L_p\left(x_i, x_j\right)=\left(\sum_{l=1}^n\left|x_i^{(l)}-x_j^{(l)}\right|^p\right)^{\frac{1}{p}} \tag{1}$$

  其中：

$$\begin{aligned}
&p=1, \quad \text{城市街区距离} \qquad L_1\text{范数} \quad L_1\left(x_i, x_j\right)=\sum_{l=1}^n\left|x_i^{(l)}-x_j^{(l)}\right| \\
&p=2, \quad \text{欧几里得距离} \qquad L_2\text{范数} \quad L_2\left(x_i, x_j\right)=\left(\sum_{l=1}^n\left|x_i^{(l)}-x_j^{(l)}\right|^2\right)^{\frac{1}{2}} \\
&p=\infty, \quad \text{最大距离} \qquad L_\infty\text{范数} \quad L_\infty\left(x_i, x_j\right)=\max_i\left|x_i^{(l)}-x_j^{(l)}\right|
\end{aligned} \tag{2}$$

1.2 正则化(regularization)

- 在训练参数化模型时，针对过拟合(高方差问题)，我们通常会有以下几种解决方法：
  1. 获取较低数据
  2. 减少特征数量
  3. 使用正则化
  4. 超参数调优
  5. 使用复杂度较低的算法

  而 `正则化`，是最有效且常用的方法，它通常也被称为 `权重衰减(weight decay)`。
- 下面我们以线性函数为例，其损失函数为

$$L(w, b)=\frac{1}{2n}\sum_{i=1}^n(W^T x^{(i)}+b-y^{(i)}) \tag{3}$$

  其中 $X^{(i)}$ 是第 i 个样本的特征，$y^{(i)}$ 是第 i 个样本的标签，W 和 b 是权重和偏置参数

正则化是通过将线性函数 $f(x)=W^Tx^{(i)}+b$ 中的权重向量的某个范数来度量其复杂性，例如 $||W||^2$ 。要保证权重向量比较小，最常用方法是将其范数作为惩罚项加到最小化损失的问题中，在线性回归中加入正则化，只需要添加正则化项（参数 λ为正则化参数）：

$$L(w,b)_{reg}=\frac{1}{2n}\sum_{i=1}^{n}(W^Tx^{(i)}+b-y^{(i)})+\frac{\lambda}{2n}||w||^2 \tag{4}$$

其中

$$\begin{aligned}||w||^2&=W^TW\\&=\sum_{i=1}^{n}w_i^2\end{aligned} \tag{5}$$

即向量参数 W 的欧几里得范数的平方,此方法成为 L_2 正则化。又因 W 可能包含很多参数，而 b 只是单个数字，所以一般只正则化参数 W ,当然也可以加上 b。

- $L2$正则化是最常见的正则化类型，你们可能听说过$L1$正则化，$L1$正则化，加的不是$L2$ 范数，而是 $\frac{\lambda}{2n}|w|$，也被称为参数向量的 L_1 范数。如果用的是$L1$正则化，w最终会是稀疏的，也就是说w向量中有很多 0，有人说这样有 利于压缩模型，因为集合中参数均为 0，存储模型所占用的内存更少。实际上，虽然$L1$正则 化使模型变得稀疏，却没有降低太多存储内存，所以我认为这并不是$L1$正则化的目的，至少 不是为了压缩模型，人们在训练网络时，越来越倾向于使用$L2$正则化。

1.3 权重衰退

- 为什么L_2正则化又被称为权重衰退？

  考虑线性回归损失函数，我们将原来的 损失函数最小化 调整为 最小化损失函数与惩罚项

$$L(w,b)=\frac{1}{2n}\sum_{i=1}^{n}(W^Tx^{(i)}+b-y^{(i)})^2 \tag{6}$$

$$\begin{aligned}L(w,b)_{reg}&=\frac{1}{2n}\sum_{i=1}^{n}(W^Tx^{(i)}+b-y^{(i)})^2+\frac{\lambda}{2n}||w||^2\\&=L(w,b)+\frac{\lambda}{2n}||w||^2\end{aligned} \tag{7}$$

则正则化前后的损失函数对 参数 W 的偏导数分别为

$$\frac{\partial L(W,b)}{\partial W}=\frac{1}{n}\sum_{i=1}^{n}(W^Tx^{(i)}+b-y^{(i)})\cdot x^{(i)} \tag{8}$$

$$
\begin{aligned}
\frac{\partial L(W,b)_{reg}}{\partial W} &= \frac{1}{n}\sum_{i=1}^{n}(W^T x^{(i)} + b - y^{(i)}) \cdot x^{(i)} + \frac{\lambda}{n}W \\
&= \frac{\partial L(W,b)}{\partial W} + \frac{\lambda}{n}W
\end{aligned} \tag{9}
$$

则根据梯度下降的更新公式（其中 η 为学习率 $\bigtriangledown_W$ 为参数 W 的梯度）

$$
W \leftarrow W - \eta \cdot \bigtriangledown_W \tag{10}
$$

w的更新为

$$
\begin{aligned}
W &\leftarrow W - \eta \cdot \frac{\partial L(W,b)}{\partial W} \\
W_{reg} &\leftarrow W - \eta \cdot \frac{\partial L(W,b)_{reg}}{\partial W}
\end{aligned} \tag{11}
$$

在添加正则化项的w更新公式中：

$$
\begin{aligned}
W_{reg} &\leftarrow W - \eta \cdot \frac{\partial L(W,b)_{reg}}{\partial W} \\
&= W - \eta(\frac{\partial L(W,b)}{\partial W} + \frac{\lambda}{n}W) \\
&= W - \frac{\eta \cdot \lambda}{n}W - \eta \cdot \frac{\partial L(W,b)}{\partial W} \\
&= (1 - \frac{\eta \cdot \lambda}{n})W - \eta \cdot \frac{\partial L(W,b)}{\partial W}
\end{aligned} \tag{12}
$$

实际上我们相当于给参数W乘以一个 $(1 - \frac{\eta \cdot \lambda}{n})$ 的倍数，该系数小于1，因此 L_2 正则化也被称为“权重衰减”，与特征选择相比，权重衰减为我们提供了一种连续的机制来调整函数的复杂度。 较小的λ值对应较少约束的 W， 而较大的 λ 值对 W 的约束更大。

1.4 为什么正则化有利于预防过拟合

- 为什么正则化有利于预防过拟合？为什么正则化可以减少方差问题？来看两个比较直观的例子