**1 信息的度量与作用**
1.1 信息熵
1.1.1 公式
1.1.2 例子
1.1.3 伯努利分布的熵
1.1.4 熵的性质
1.2 联合熵
1.3 条件熵
1.3.1 公式
1.3.2 推导
1.4 交叉熵
1.4.1 公式
1.4.2 性质
1.4.3 交叉熵误差函数
1.5 互信息
1.5.1 定义公式
1.5.2 公式推导
1.6 KL散度（Kullback-Leibler散度）
1.6.1 公式
1.6.2 性质
1.7 js散度(Jensen-Shannon散度)
1.7.1 公式
1.7.2 性质
**2 图示**
2.1 熵、条件熵、联合熵和互信息的关系
2.2 熵相关的各个量之间的关系

# 1 信息的度量与作用

## 1.1 信息熵

### 1.1.1 公式

- 一个离散随机变量$X$的可能取值为$X = x_1, x_2, \ldots, x_n$，而对应的概率为$p_i = p(X = x_i)$,如下

| $x_1$ | $x_2$ | $x_3$ | $x_4$ | …… | $x_n$ |
|---|---|---|---|---|---|
| p($x_1$) | p($x_2$) | p($x_3$) | p($x_4$) | …… | p($x_n$) |

在信息论中，某个信息 $x_i$ 出现的不确定性的大小定义为 $x_i$ 所携带的信息量，用 $I(x_i)$ 表示。$I(x_i)$ 与信息 $x_i$ 出现的概率 $p(x_i)$ 之间的关系为

$$\begin{aligned} I(x_i) &= \log \frac{1}{p(x_i)} \\ &= -\log p(X_i) \end{aligned} \tag{1}$$

以上是求单一信息的信息量；求全部信息的平均信息量，即

1. 离散型随机变量的信息熵 定义为：

$$\begin{aligned} H(x) &= -\sum_{i=1}^{n} p(x_i) \log p(x_i) \\ &= H(P) \end{aligned} \tag{2}$$

2. 连续型随机变量的信息熵 定义为：

$$H(x) = -\int f(x) \log(f(x)) dx \tag{3}$$

规定当 $p(x_i) = 0$ 时，$p(x_i) \log p(x_i) = 0$。

- 信息熵 是一个平均信息量，可以解释为：用基于P的编码去编码来自P的样本，其最优编码平均所需要的比特个数。

### 1.1.2 例子

- 以《数学之美》中一个小例子来理解上述的公式，世界杯有32支球队，赛后我问一个知道比赛的观众“哪支球队是冠军”？他不愿告诉我，让我猜，并且没猜一次，他需要收一块钱(一块钱能买1G流量,上网查它不香吗？)才肯告诉我是否才对，我可以吧球队编号从1到32，然后提问“冠军是在1-16号球队中吗？”假如他告诉我猜错了，那么肯定就在17-32号球队中，这样只需要提问5次($2^5 = 32$)，就能知道哪只球队是冠军。所以谁是世界杯冠军这条消息只值5元($\log_2^{32} = 5$)。

  香农用“比特”(Bit)来度量信息量，一个比特是一位二进制数，在计算机中，一个字节是8比特。则在上面的例子中，这条信息量是5比特，信息量的比特数和所有可能情况的对数函数有关。即信息量

$$
\begin{aligned}
I(x_i) &= \log_2 \frac{1}{p(x_i)} \\
&= -\log_2 p(X_i) \\
&= \log_2 \frac{1}{\frac{1}{32}} \\
&= -\log_2 \frac{1}{32} \\
&= 5(bit)
\end{aligned} \tag{4}
$$

当然我们发现实际上可能并不需要5次才能猜中，因为巴西，德国，意大利这样的球队会比其他球队更有可能夺冠，所以第一次猜测时不需要等分，而可以将少数热门球队分为一份，其他的另分为一份，重复这个过程，有可能3次或者4次就能猜出结果。所以，当没只球队夺冠的可能性(概率)不等时(使用$p_1, p_2, \ldots, p_{32}$分别表示这32只球队夺冠的概率)，“谁是世界杯冠军”的信息量比5比特少。香农指出，它准确的信息量是

$$
\begin{aligned}
H(x) &= -\sum_{i=1}^{n} p(x_i) \log p(x_i) \\
&= H(P) \\
&= -(p_1 \cdot \log p_1 + p_2 \cdot \log p_2 + \cdots + p_{32} \cdot \log p_{32})
\end{aligned} \tag{5}
$$

香农称之为信息熵，一般用H表示，单位是比特。当这32支球队夺冠概率相同时，对应的信息熵等于5比特。

- 汉字编码

  有一本50万字的书，假设每个字出现的概率相同，那么每个字携带的信息量是

$$
\log_2^{500000} \approx 18.93bit \tag{6}
$$

  即加入每个字等概率，大约需要19比特（19位二进制数）表示一个汉字

  这本书总携带的信息量为

$$
\begin{aligned}
500000 * \log_2^{500000} &\approx 500000 * 18.93 \text{ Bit} \\
&= 9465000 \text{ Bit} \\
&= (9465000/8) \text{ Byte} \\
&= 1183125 \text{ Byte} \\
&= (1183125/1024/1024)\text{G} \\
&\approx 1.13\text{G}
\end{aligned} \tag{7}
$$

  即在假设每个字出现的概率相同的情况下，50万字的书携带的信息量为9465000比特；

  但是汉子使用频率不均等，10%的汉字占常用文本的95%以上。且在考虑上下文的情况下，每个汉字的信息熵只有5bit左右，即50万字携带250万比特的信息，采用较好的算法压缩，整本书可以存成一个320k的文件，若直接用两字节的国标编码存储这本书，大约需要1MB大小，是压缩文件的3倍，这两个数据量的差异在信息论中叫冗余度，且250万比特在这只是一个平均数，同样两本50万字的书，所含的信息量可以相差很多。如果一本书重复的内容很多，它的信息量就小，冗余度就大。且不同语言的冗余度差别也很大，一本很厚的英文书翻译成中译本一般会薄很多。

### 1.1.3 伯努利分布的熵

- 伯努利分布(两点分布、0-1分布)

| x | 1 | 0 |
|---|---|---|
| 概率 | p | 1-p |

$$
\begin{aligned}
H(x) &= -\sum_x p(x)\log p(x) \\
&= -p\log p-(1-p)\log(1-p)
\end{aligned} \tag{8}
$$

### 1.1.4 熵的性质

- 对于离散型随机变量，当其服从均匀分布时，熵有极大值；
- 对与离散型随机变量，取某一个值的概率为1，其他所有值的概率为0时，熵有极小值。

## 1.2 联合熵

- 联合熵（Joint Entropy）是熵对多维概率分布的推广，它描述了一组随机变量的不确定性。以二维随机向量为例，有两个离散型随机变量X和Y，它们的联合概率质量函数为p(x)，联合熵定义为：

$$
H(X,Y)=-\sum_x\sum_y p(x,y)\log p(x,y) \tag{9}
$$

推广到多个随机变量，有：

$$
H(X_1,X_2,\ldots,X_n)=-\sum_x\sum_y p(x_1,x_2,\ldots,x_n)\log p(x_1,x_2,\ldots,x_n) \tag{10}
$$

对于连续型随机向量（X，Y），假设联合概率密度函数为p(x,y)，其联合熵为二重积分

$$
H(X,Y)=-\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} p(x,y)\log p(x,y)dxdy \tag{11}
$$

即

1. 离散型随机变量的联合熵为

$$
H(X,Y)=-\sum_x\sum_y p(x,y)\log p(x,y) \tag{12}
$$

2. 连续型随机变量的联合熵为

$$
H(X,Y)=-\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} p(x,y)\log p(x,y)dxdy \tag{13}
$$

## 1.3 条件熵

### 1.3.1 公式

- 假定X和Y是两个随机变量，X是我们需要了解的。假定我们现在知道了X的随机分布$P(X)$,那么也就知道了X的熵

$$
H(X)=-\sum_{x\in X} p(x)\log p(x) \tag{14}
$$

那么他的不确定性就是这么大。现在假定我们还知道Y的一些情况，包括它和X的联合概率分布，以及Y取不同值时X的条件概率分布。则定义在Y的条件下的条件熵为：

$$
H(X|Y)=-\sum_{x\in X,y\in Y} p(x,y)\log p(x|y) \tag{15}
$$

且 $H(X) \geq H(X|Y)$(因为$H(X) - H(X|Y)$其实就是互信息，互信息大于等于0)。也就是说，`多了Y的信息之后，关于X的不确定性下降了`。

- 在统计语言模型中，如果把Y看成前一个字，那么在数学上就证明了二元模型的不确定性是小于一元模型的，同理可以定义有两个条件的条件熵为

$$H(X|Y,Z) = -\sum_{x\in X, y\in Y, z\in Z} p(x,y,z)\log p(x,y,z) \tag{16}$$

还可以证明$H(X|Y) \geq H(X|Y,Z)$,也就是说，三元模型应该比二元的好。

- 当什么情况下，$H(X) = H(X|Y)$ 呢？等号成立说明增加了信息，不确定性却没有降低。这可能么？答案是肯定的，如果我们获取的信息与药研究的事物毫无关系，等号就成立。
- 用一句话概括这一节：信息的作用在于消除不确定性，自然语言处理的大量问题就是寻找相关的信息

### 1.3.2 推导

- $H(X|Y) = -\sum_{x\in X, y\in Y} p(x,y)\log p(x|y)$

$$\begin{aligned}
H(X|Y) &= \sum_{y\in Y} p(y) H(X|Y=y) \\
&= -\sum_{y\in Y} p(y) \sum_{x\in X} p(x|y)\log p(x|y) \\
\because\ \ p(x,y) &= \frac{p(x,y)}{p(y)} \\
\therefore\ \ &= -\sum_{x\in X}\sum_{y\in Y} p(y)\cdot\frac{p(x,y)}{p(y)}\log p(x|y) \\
&= -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(x|y)
\end{aligned} \tag{17}$$

- $H(X|Y) = H(X,Y) - H(Y)$

$$\begin{aligned}
H(X|Y) &= -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(x|y) \\
\because\ \ p(x,y) &= \frac{p(x,y)}{p(y)} \\
\therefore\ \ &= -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log\frac{p(x,y)}{p(y)} \\
&= -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(x,y) - \left(-\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(y)\right) \\
\because\ \ p(y) &= \sum_{x\in X} p(x,y) \\
\therefore\ \ &= -\sum_{x\in X}\sum_{y\in Y} p(x,y)\log p(x,y) - \left(-\sum_{y\in Y} p(y)\log p(y)\right) \\
&= H(X,Y) - H(Y)
\end{aligned} \tag{18}$$

---

## 1.4 交叉熵

### 1.4.1 公式

- 针对离散变量x的概率分布 $p(x)$ , $q(x)$

| $x_1$ | $x_2$ | $x_3$ | $x_4$ | ..... | $x_n$ |
|---|---|---|---|---|---|
| p($x_1$) | p($x_2$) | p($x_3$) | p($x_4$) | ..... | p($x_n$) |
| q($x_1$) | q($x_2$) | q($x_3$) | q($x_4$) | ..... | q($x_5$) |

其 交叉熵 定义为：

$$\begin{aligned} H(P,Q) &= \sum_{i=1}^{n} p(x_i) \log \frac{1}{q(x_i)} \\ &= -\sum_{i=1}^{n} p(x_i) \log q(x_i) \end{aligned} \tag{19}$$

- 交叉熵 可解释为：用基于p的编码去编码来自Q的样本，所需要的比特个数

---

### 1.4.2 性质

- 如果连个概率分布完全相等，交叉熵退化为熵
- 交叉熵不是距离，不具有对称性，也不满足三角不等式
- 当两个概率分布相等时，交叉熵有极小值
- 交叉熵与相对熵的关系，都反映了两个概率分布的差异程度。

### 1.4.3 交叉熵误差函数

- 举个例子，在神经网络中，对于 4 分类问题，如果某个 样本的真实标签是 4 类，那么标签的 One-hot 编码为[0,0,0,1]，即这张图片的分类是唯一 确定的，它属于第 4 类的概率$P(y$为 4$|\boldsymbol{x})$ = 1，不确定性为 0，它的熵可以简单的计算为:

$$-0 \bullet \log 0 - 0 \bullet \log 0 - 0 \bullet \log 0 - 1 \bullet \log 1 = 0 \tag{20}$$

  也就是说，对于确定的分布，熵为 0，不确定性最低。

  由于$P(i) \in [0,1]$，log2 $P(i) \leq 0$，因此熵$H(P)$总是大于等于 0。当熵取得最小值 0 时， 不确定性为 0。分类问题的 One-hot 编码的分布就是熵为 0 的典型例子。

- 当分类问题中 y 的编码分布 $p$采用 One-hot 编码$\boldsymbol{y}$时:$H(p)$ = 0，此时

$$H(p,q) = H(p) + D_{KL}(p||q) = D_{KL}(p||q) \tag{21}$$

  退化到真实标签分布$\boldsymbol{y}$与输出概率分布$\boldsymbol{o}$之间的 KL 散度上。

  则根据KL散度的定义，我们推导分类问题中交叉熵的计算表达式:

$$\begin{aligned} H(p,q) &= D_{KL}(p||q) \\ &= \sum y_j \log(\frac{y_j}{o_j}) \\ &= 1 * \log \frac{1}{o_i} + \sum_{j \neq i} 0 * \log \frac{0}{o_j} \\ &= -\log o_i \end{aligned} \tag{22}$$

  其中$i$为 One-hot 编码中为 1 的索引号，也是当前输入的真实类别。可以看到，损失函数只与真实 类别$i$上的概率$oi$有关，对应概率$oi$越大，$H(p,q)$越小。当对应类别上的概率为 1 时，交叉 熵$H(p,q)$取得最小值 0，此时网络输出$\boldsymbol{o}$与真实标签$\boldsymbol{y}$完全一致，神经网络取得最优状态。
  因此最小化交叉熵损失函数的过程也是最大化正确类别的预测概率的过程 。从这个角 度去理解交叉熵损失函数，非常地直观易懂。

# 1.5 互信息

## 1.5.1 定义公式

- 从条件熵中我们知道，当获取的信息和要研究的食物”有关系时“，这些信息才能帮助我们消除不确定性。如何衡量获取信息和要研究事物“有关系”呢？比如常识告诉我们，一个随机事件“今天深圳下雨”和另一个随机事件“过去24小时深圳空气湿度”相关性很大，但是相关性到底有多大？怎么衡量？再比如“过去24小时深圳空气湿度”似乎就和“北京天气”相关性不大。
- 香农在信息论中提出”互信息“的概念作为两个随机事件“相关性”的量化度量
- 假定有两个随机事件X和Y，他们的互信息定义如下：

$$
\begin{aligned}
I(X:Y) &= H(X) - H(X|Y) \\
&= H(Y) - H(Y|X) \\
&= H(X) + H(Y) - H(X,Y) \\
&= H(X,Y) - H(X|Y) - H(Y|X) \\
&= \sum_{x\in X, y\in Y} p(x,y)\log\frac{p(x,y)}{p(x)p(y)}
\end{aligned}
\tag{23}
$$

  当X和Y完全相同时互信息的取值是H(X)，同时H(X)=H(Y)；当二者完全无关时互信息取值为0。
- 所谓两个时间相关性的量化度量，就是在了解了其中一个Y的前提下，对消除另一个X不确定性所提供的信息量。

## 1.5.2 公式推导

- 两种推导公式
- $I(X:Y) = H(X) - H(X|Y)$

$$
\begin{aligned}
I(X:Y) &= H(X) - H(X|Y) \\
&= -\sum_x p(x)\log p(x) - \left(-\sum_{x,y} p(x,y)\log p(x,y)\right) \\
\because\ p(x) &= \sum_y p(x,y) \\
\therefore &= \sum_{x,y} p(x,y)\log p(x|y) - \sum x,yp(x,y)\log p(x) \\
&= \sum_{x,y} p(x,y)\log\frac{p(x|y)}{p(x)} \\
\because\ p(x|y) &= \frac{p(x,y)}{p(y)} \\
\therefore &= \sum_{x,y} p(x,y)\log\frac{p(x,y)}{p(x)p(y)}
\end{aligned}
\tag{24}
$$

- $I(X:Y) = H(X) + H(Y) - H(X,Y)$

$$
\begin{aligned}
I(X:Y) &= H(X)+H(Y)-H(X,Y) \\
&= -\sum_x p(x)\log p(x) - \left(-\sum_y p(y)\log p(y)\right) - \left(-\sum_{x,y} p(x,y)\log p(x,y)\right) \\
&= \sum_{x,y} p(x,y)\log p(x,y) - \left(\sum_x p(x)\log p(x) - \sum_y p(y)\log p(y)\right) \\
\because\ p(x) &= \sum_y p(x,y) \\
\therefore &= \sum_{x,y} p(x,y)\log p(x,y) - \left(\sum_{x,y} p(x,y)\log p(x) - \sum_{x,y} p(x,y)\log p(y)\right) \\
&= \sum_{x,y} p(x,y)\log \frac{p(x,y)}{p(x)p(y)}
\end{aligned} \tag{25}
$$

---

# 1.6 KL散度（Kullback-Leibler散度）

- KL散度又称相对熵，注意与交叉熵区别
- KL散度的概念来源于概率论和信息论中。KL散度又被称为：`相对熵`、互熵、鉴别信息、Kullback熵、Kullback-Leible散度(即KL散度的简写)。在机器学习、深度学习领域中，KL散度被广泛运用于变分自编码器中(Variational AutoEncoder,简称VAE)、EM算法、GAN网络中

## 1.6.1 公式

- KL散度或相对熵可通过下式得出

$$
\begin{aligned}
D_{KL}(P||Q) &= H(P,Q)-H(P) \\
&= -\sum_{i=1}^{n} p(x_i)\log q(x_i) - (-\sum_{i=1}^{n} p(x_i)\log p(x_i)) \\
&= \sum_{i=1}^{n} p(x_i)\log p(x_i) - \sum_{i=1}^{n} p(x_i)\log q(x_i) \\
&= \sum_{i=1}^{n} p(x_i)\left[\log p(x_i) + \log(\frac{1}{q(x_i)})\right] \\
&= \sum_{i=1}^{n} p(x_i)\log \frac{p(x_i)}{q(x_i)}
\end{aligned} \tag{26}
$$

- `KL散度公式`
  1. `离散型随机变量(P,Q为离散型)`：

$$
D_{KL}(P||Q) = \sum_{i=1}^{n} p(x_i)\log \frac{p(x_i)}{q(x_i)} \tag{27}
$$

  2. `连续型随机变量(P,Q为离散型)：`

$$
D_{KL}(P||Q) = \int_X P(x_i) * \left[\log \frac{p(x_i)}{q(x_i)}\right] dx \tag{28}
$$

- `KL散度的意义`：

  在统计学意义上来说，KL散度可以用来`衡量两个分布之间的差异程度`。若两者差异越小，KL散度越小，反之亦反。当两分布一致时，其KL散度为0。正是因为其可以衡量两个分布之间的差异，所以在VAE、

EM、GAN中均有使用到KL散度。

### 1.6.2 性质

- 对两个完全相同的函数，他们的相对熵等于0
- 相对熵越大，两个函数差异越大；反之，相对熵越小，两个函数差异越小。
- 对于概率分布或者概率密度函数，如果取之均大于0，相对熵可以度量两个随机分布的差异性。
- 相对熵是不对称的，即$D_{kl}(P||Q) \neq D_{kl}(Q||P)$

---

## 1.7 js散度(Jensen-Shannon散度)

### 1.7.1 公式

- 针对KL散度的不对称性，詹森和香农提出一种新的相对熵的计算方法，定义于两个概率分布上，根据KL散度构造，同样描述了两个概率分布的差异，且具有对称性

$$D_{JS}(p||q) = \frac{1}{2}D_{KL}(p||m) + \frac{1}{2}D_{KL}(q||m) \tag{29}$$

其中概率分布m为p和q的均值

$$m(x) = \frac{p(x)+q(x)}{2} \tag{30}$$

### 1.7.2 性质

- JS三度非负，JS散度越大，两个概率分布之间的差异越大
- JS散度具有对称性
- 当且仅当两个概率分布相同时，JS散度等于0

$$\begin{aligned}
\because m(x) &= \frac{p(x)+q(x)}{2} = p(x) = q(x) \\
\therefore D_{JS}(p||q) &= \frac{1}{2}D_{KL}(p||m) + \frac{1}{2}D_{KL}(q||m) \\
&= \frac{1}{2}D_{KL}(p||p) + \frac{1}{2}D_{KL}(p||p) \\
&= D_{KL}(p||p) \\
&= 0
\end{aligned} \tag{31}$$

---

# 2 图示

## 2.1 熵、条件熵、联合熵和互信息的关系

- 如下图

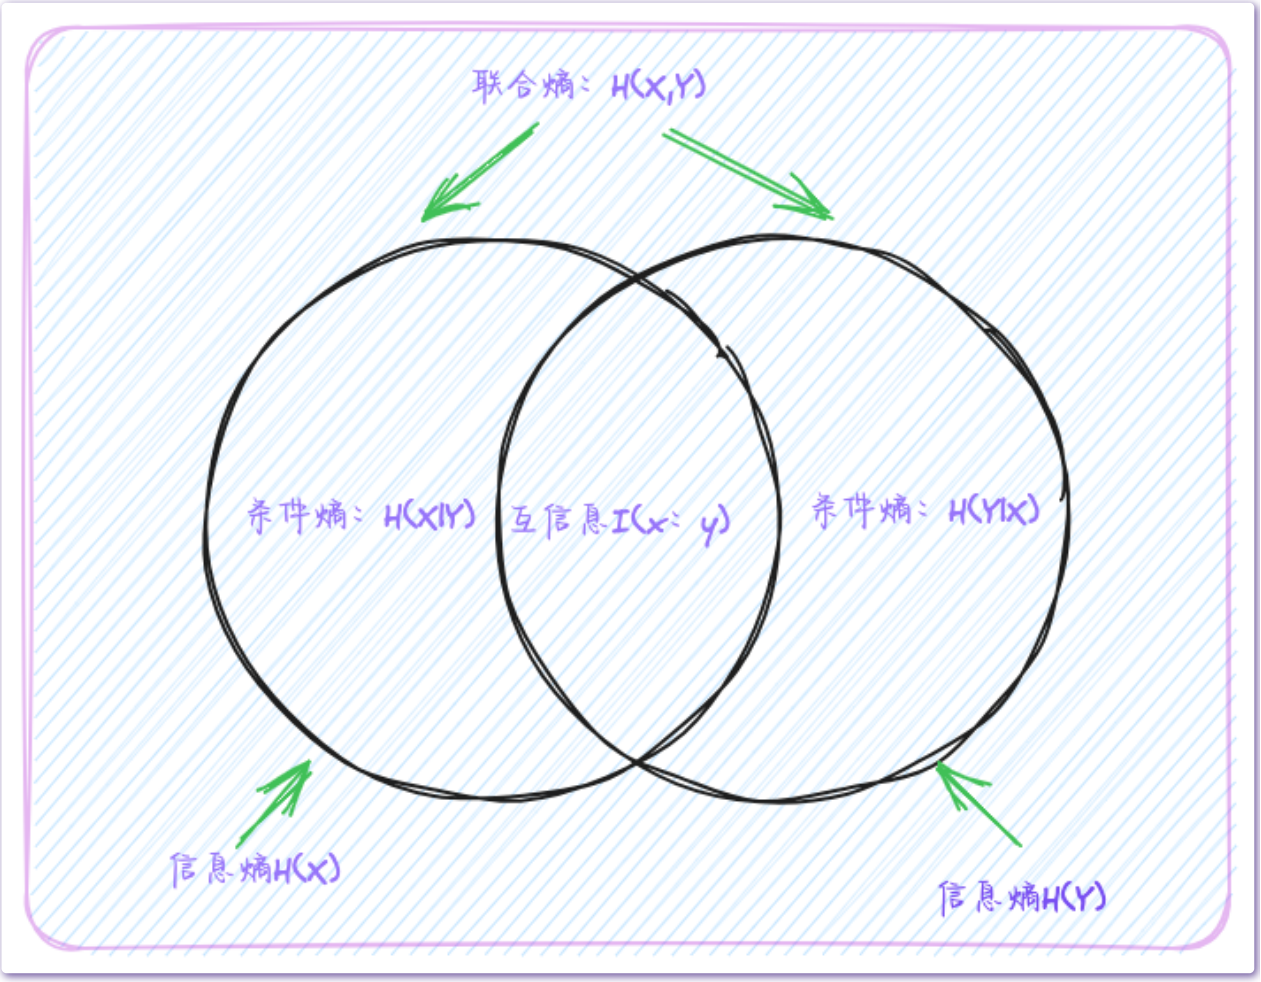


## 2.2 熵相关的各个量之间的关系

- 如下图

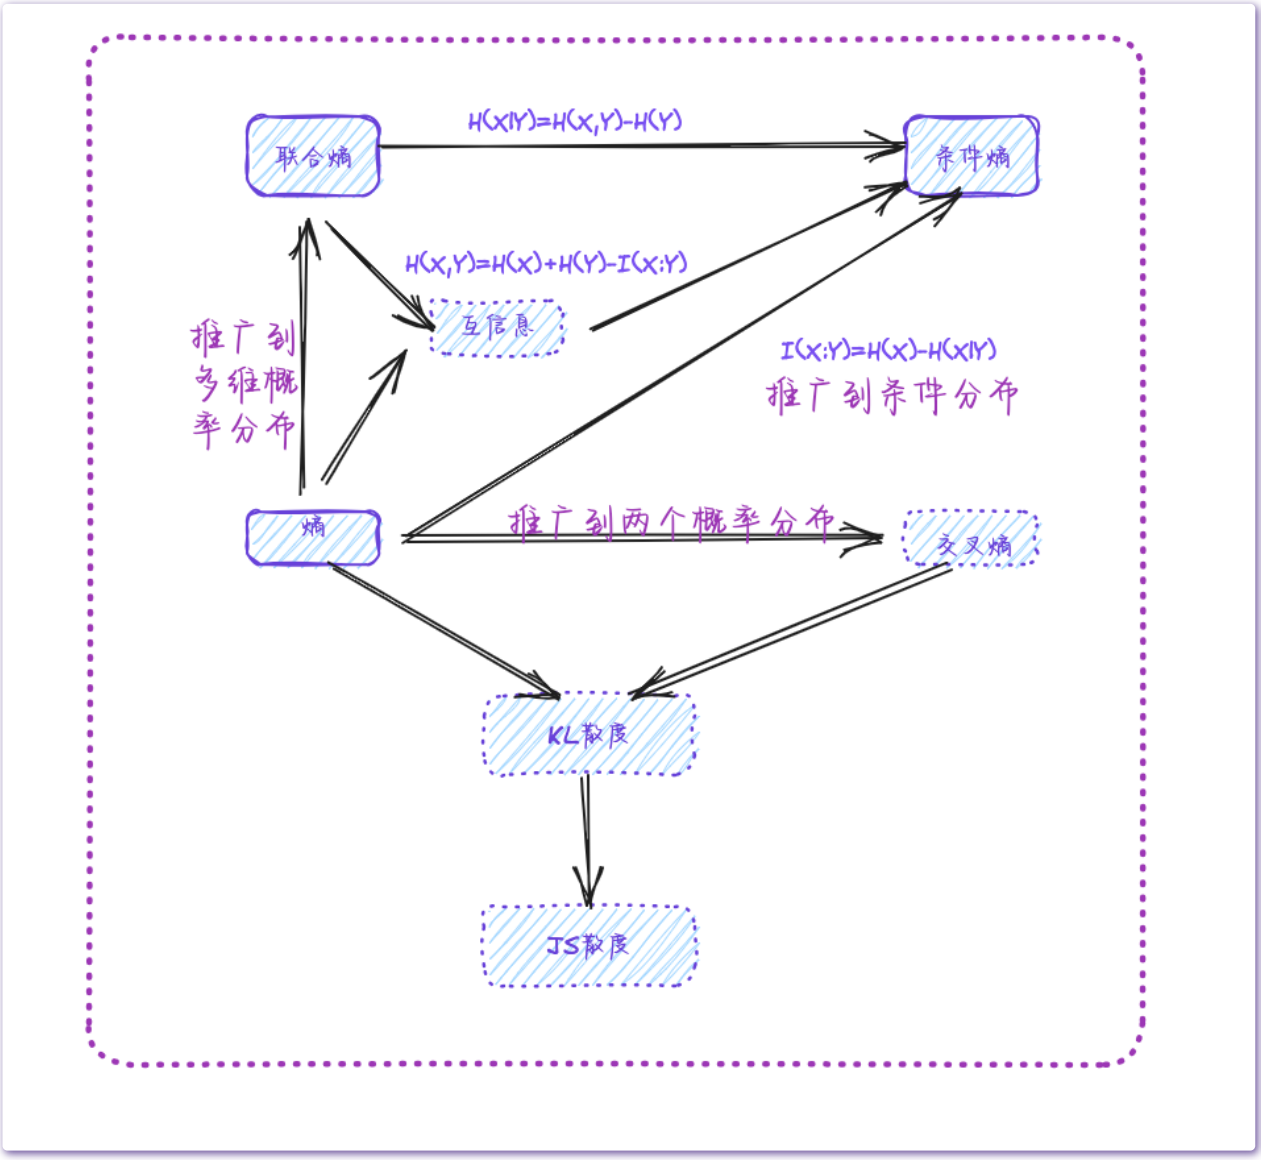
联合熵
H(X|Y)=H(X,Y)-H(Y)
条件熵
H(X,Y)=H(X)+H(Y)-I(X:Y)
互信息
推广到多维概率分布
I(X:Y)=H(X)-H(X|Y)
推广到条件分布
熵
推广到两个概率分布
交叉熵
KL散度
JS散度