- cat /etc/os-release

```
cat /etc/os-release
```

```
[root@autodl-container-ac5b409425-a71a55f6 ~]# cat /etc/os-release

NAME="openEuler"

VERSION="24.03 (LTS)"

ID="openEuler"

VERSION_ID="24.03"

PRETTY_NAME="openEuler 24.03 (LTS)"

ANSI_COLOR="0;31"
```

- dnf

```

# 更新软件包索引
sudo dnf makecache

# 更新软件包
sudo dnf update

# 安装lsof
sudo dnf install lsof

```

安装docker

```

# 安装docker
sudo dnf install docker-engine

# 启动docker服务
sudo systemctl start docker
```

- 安装qwen3-32b

```
pip install modelscope
```

```python
import os
import certifi
os.environ['REQUESTS_CA_BUNDLE'] = certifi.where()


from modelscope.hub.snapshot_download import snapshot_download

model_name = "Qwen/Qwen3-8B"
model_name = "Qwen/Qwen2.5-7B-Instruct"

cache_dir = "/root/autodl-tmp"  # 替换为你希望的路径

snapshot_download(model_name, cache_dir=cache_dir)
```

```
/root/autodl-tmp/Qwen/Qwen3-8B
```

直接命令行下载 (需要完整的模型保存)

```
modelscope download --model Qwen/Qwen3-0.6B --local_dir /root/Qwen/Qwen3-0.6B
```

- 更新

```
sudo apt-get update
```

- 硬盘分区

```
# 查看未分区磁盘：vdb
lsblk

# 进行硬盘分区
fdisk /dev/vdb

n
p
1
回车
回车
w

# 查看磁盘设备 可看到刚分区出来的vdb1
fdisk -l

# 将/dev/vdb1格式化为ext4
mkfs.ext4 /dev/vdb1

# 查看已挂载信息
df -h

# 临时挂载，设备关机会自动卸载
```

```
mount /dev/vdb1 /data

# 永久挂载，在最后加上
echo '/dev/vdb1 /data ext4 defaults,nofail 0 0' >> /etc/fstab

# 重启示例，使配置文件生效
reboot
```

- 安装docker

```
sudo curl -fsSL https://get.docker.com| bash -s docker --mirror Aliyun

docker --version

sudo service docker start
```

系统盘不够,挂载了200G的数据盘，修改配置文件将默认的路径改掉

```
#
sudo systemctl stop docker

#
sudo mv /var/lib/docker /data/docker

#
vim /etc/docker/daemon.json
{
  "data-root": "/data/docker"
}
#
sudo systemctl start docker

# 验证
docker info | grep "Docker Root Dir"
```

- yum安装

```
sudo yum install -y yum-utils device-mapper-persistent-data lvm2
```

- 拉取镜像

  昇腾镜像仓库

> https://www.hiascend.com/developer/ascendhub

搜索mindie

昇腾镜像仓库
昇腾开放Docker镜像仓库，提供昇腾软件Docker镜像
筛选
分类
MindCluster
推理镜像
训练镜像
推理微服务
操作系统
其他
架构
ARM
x86
综合排序
最新优先
请输入镜像名称
mis-tei
推理镜像 arm64
该镜像基于text embedding inference 适配昇腾NPU卡提供embedding、reranker等服务化接口，接口兼容开源text embedding
2.3
4115
cann
训练镜像 arm64 x86_64
CANN（Compute Architecture for Neural Networks）是昇腾针对AI场景推出的异构计算架构，对上支持多种AI框架，对下服务AI处理器与编
1.0
1281
ragsdk
推理镜像 arm64
该镜像具备运行RAG SDK所需的基础环境，可快速上手进行RAG开发。
--
120
mindie
推理镜像 arm64 x86_64
该镜像已具备模型运行所需的基础环境，包括：`CANN`、`FrameworkPTAdapter`、`MindIE`与`ATB-Models`，可实现模型快速上
2.3
31330
multimodalsdk
推理镜像 arm64
Multimodal SDK 推理镜像，支持在昇腾上快速、高性能构建多模态应用
bge-reranker-v2-m3
推理微服务 arm64
bge-reranker-v2-m3 向量化模型微服务，具备精细化候选排序与相关性优化，支持RAG结果重排、搜索排序增强。

昇腾社区首页
中文
qinchihongye
Ascend
开发者
主页
开发
文档
活动
学习
论坛
博客
开发者计划
下载
支持
昇腾镜像仓库 > mindie
mindie
最新版本：2.0.RC2-800I-A3-py311-openeuler24.03-lts
2025/05/23更新
大小：12 GB
发布者：MindIE
31330次下载
2.3
我要评分
arm64
x86_64
镜像概述
镜像版本
该镜像版本受控需要申请权限后才能下载
版本
文件大小
更新时间
架构
操作
2.0.RC2-800I-A3-py311-openeuler24.03-lts
12 GB
2025/05/23
arm64 x86_64
立即下载
2.0.RC2-800I-A2-py311-openeuler24.03-lts
12 GB
2025/05/23
arm64 x86_64
立即下载

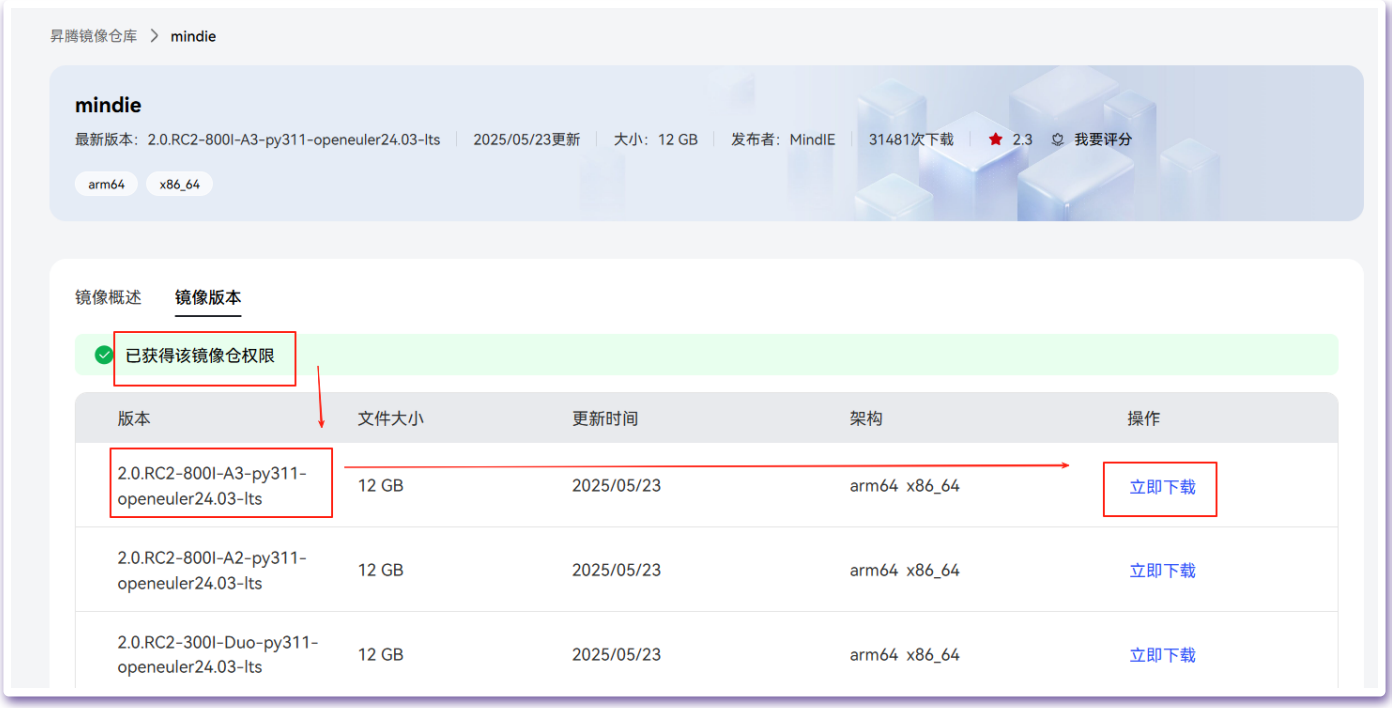
昇腾镜像仓库 > mindie
mindie
最新版本：2.0.RC2-800I-A3-py311-openeuler24.03-lts
2025/05/23更新
大小：12 GB
发布者：MindIE
31481次下载
2.3
我要评分
arm64
x86_64
镜像概述
镜像版本
已获得该镜像仓权限
版本
文件大小
更新时间
架构
操作
2.0.RC2-800I-A3-py311-openeuler24.03-lts
12 GB
2025/05/23
arm64 x86_64
立即下载
2.0.RC2-800I-A2-py311-openeuler24.03-lts
12 GB
2025/05/23
arm64 x86_64
立即下载
2.0.RC2-300I-Duo-py311-openeuler24.03-lts
12 GB
2025/05/23
arm64 x86_64
立即下载

mindie
arm64
x86_64
镜像概述
镜像版本
已获得该镜像仓权限
版本
操作
镜像下载
前提条件：
准备一台计算机，要求安装的docker版本必须为1.11.2及以上
操作步骤：
Step 1. 以root登录docker所在的虚拟机
Step 2. 获取登录访问权限，并复制到节点执行
docker login -u
Step 3. 输入密码
****
Step 4. 下载镜像
arm架构： docker pull --platform=arm64 swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:2.0.RC2-800I-A3-py311-openeuler24.03-lts
x86架构： docker pull --platform=amd64 swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:2.0.RC2-800I-A3-py311-openeuler24.03-lts
自适应架构： docker pull swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:2.0.RC2-800I-A3-py311-openeuler24.03-lts
立即下载

- 启动命令

```
docker run -it -d --net=host --shm-size=1g \
    --privileged \
    --name mindie_llm_qwen3_32b \
    --device=/dev/davinci_manager \
    --device=/dev/hisi_hdc \
    --device=/dev/devmm_svm \
    -v /usr/local/Ascend/driver:/usr/local/Ascend/driver:ro \
    -v /usr/local/sbin:/usr/local/sbin:ro \
    -v /path-to-weights:/path-to-weights:ro \
    swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:2.0.RC2-800I-A3-py311-openeuler24.03-lts bash
```

0.0.1 Docker 运行参数详细解释

以下是 `docker run` 命令参数的详细说明，整理为 Markdown 表格：

参数	含义	作用说明
`-it`	交互式终端模式	分配一个伪终端（TTY）并保持 STDIN 打开，允许用户与容器交互
`-d`	后台运行模式	容器在后台运行（detached 模式）
`--net=host`	共享主机网络	**主机网络模式**：将容器的网络栈直接映射到主机网络栈,这意味着容器内部的服务可以直接通过主机 IP 和端口访问，而不需要端口映射。
`--shm-size=1g`	共享内存大小	设置容器内 `/dev/shm` 的大小为 1GB, 较大的共享内存来避免性能瓶颈,如果不设置的话在启动的时候一定会报共享内存不足的错误
`--privileged`	特权模式	赋予容器完全访问主机硬件和内核的权限
`--name mindie_llm_qwen3_32b`	容器名称	指定容器名称为 mindie_llm_qwen3_32b
`--device=/dev/davinci_manager`	挂载昇腾 AI 处理器管理设备	允许容器访问华为昇腾 NPU 的管理接口（关键 AI 加速设备）
`--device=/dev/hisi_hdc`	挂载昇腾 Host 控制设备	提供容器对昇腾 NPU 的 Host 控制能力
`--device=/dev/devmm_svm`	挂载昇腾内存管理设备	支持容器使用昇腾 NPU 的共享虚拟内存机制
`-v /usr/local/Ascend/driver:ro`	只读挂载昇腾驱动目录	容器只读访问宿主机的昇腾 NPU 驱动程序（`:ro` 表示只读）
`-v /usr/local/sbin:ro`	只读挂载系统工具目录	容器只读访问宿主机的系统管理工具（可能包含昇腾相关工具）
`-v /path-to-weights:ro`	只读挂载模型权重目录	容器只读访问宿主机的模型权重文件（需替换 `/path-to-weights` 为实际路径）
`swr.cn-south-1.myhuaweicloud.com/...`	Docker 镜像地址	华为云 SWR 提供的 MindIE 框架镜像（预装昇腾环境 + OpenEuler 24.03 + Python 3.11）
`bash`	启动命令	容器启动后执行 `bash` shell（保持容器持续运行）

```bash
docker exec -it mindie_llm_qwen3_32b bash

pip uninstall transformers
pip install transformers==4.51.0
```

config.json文件需要修改torch_dtype类型为float16，否则可能导致模型服务化失败。

```bash
vim /root/autodl-tmp/Qwen/Qwen3-8B/config.json

chmod 750 /root/autodl-tmp/Qwen/Qwen3-8B/config.json

qwen3 改成 qwen2?
```

```
{
  "architectures": [
    "Qwen3ForCausalLM"
  ],
  "attention_bias": false,
  "attention_dropout": 0.0,
  "bos_token_id": 151643,
  "eos_token_id": 151645,
  "head_dim": 128,
  "hidden_act": "silu",
  "hidden_size": 4096,
  "initializer_range": 0.02,
  "intermediate_size": 12288,
  "max_position_embeddings": 40960,
  "max_window_layers": 36,
  "model_type": "qwen3",
  "num_attention_heads": 32,
  "num_hidden_layers": 36,
  "num_key_value_heads": 8,
  "rms_norm_eps": 1e-06,
  "rope_scaling": null,
  "rope_theta": 1000000,
  "sliding_window": null,
  "tie_word_embeddings": false,
  "torch_dtype": "bfloat16",
  "transformers_version": "4.51.0",
  "use_cache": true,
  "use_sliding_window": false,
  "vocab_size": 151936
}
~
~
~
~
```

修改为float16

```
vim /usr/local/Ascend/mindie/latest/mindie-service/conf/config.json


cd /usr/local/Ascend/mindie/latest/mindie-service/bin

export MINDIE_TO_STDOUT=true
export NPU_MEMORY_FRACTION=0.95

./mindieservice_daemon
```

1. httpsEnabled
2. npuDeviceIds
3. worldSize

```
执行如下脚本加载环境变量 否则会报错 Failed to init infer backend manager

# 配置CANN环境，默认安装在/usr/local目录下
source /usr/local/Ascend/ascend-toolkit/set_env.sh
# 配置加速库环境
source /usr/local/Ascend/nnal/atb/set_env.sh

source /usr/local/Ascend/atb-models/set_env.sh
source /usr/local/Ascend/mindie/set_env.sh
source /usr/local/Ascend/mindie/latest/mindie-service/set_env.sh

export PYTHONPATH=/usr/local/lib/python3.11/site-packages:$PYTHONPATH

export PYTHONPATH=/usr/local/lib64/python3.11/site-packages:$PYTHONPATH

各组件日志打屏
export MINDIE_LOG_TO_STDOUT=true
```

```
cd /usr/local/Ascend/atb-models/atb_llm/models/

cp -R qwen2
```

- 查看版本信息

```
cat /usr/local/Ascend/mindie/latest/version.info
```

```
[root@autodl-container-ac5b409425-a71a55f6 tmp]# cat /usr/local/Ascend/mindie/latest/version.info
Ascend-mindie : MindIE 2.0.RC2.B080
mindie-rt: 2.0.RC2.B080
mindie-torch: 2.0.RC2.B080
mindie-service: 2.0.RC2.B080
mindie-llm: 2.0.RC2.B080
mindie-sd:2.0.RC2.B080
Platform : aarch64
[root@autodl-container-ac5b409425-a71a55f6 tmp]#
```

by: 亲持红叶（MZC）

查看cann

> cat /usr/local/Ascend/ascend-toolkit/latest/$(uname -m)-linux/ascend_toolkit_install.info

```
[root@autodl-container-ac5b409425-a71a55f6 aarch64-linux]# cat /usr/local/Ascend/ascend-toolkit/latest/$(uname -m)-linux/asce
nd_toolkit_install.info
package_name=Ascend-cann-toolkit
version=8.1.RC1
innerversion=V100R001C21SPC001B238
compatible_version=[V100R001C15],[V100R001C18],[V100R001C19],[V100R001C20],[V100R001C21]
arch=aarch64
os=linux
path=/usr/local/Ascend/ascend-toolkit/8.1.RC1/aarch64-linux
[root@autodl-container-ac5b409425-a71a55f6 aarch64-linux]#
```

by：亲持红叶（MZC）

- 升级atb_models

```
cd /tmp
git clone https://gitee.com/ascend/ModelLink.git
cd ModelLink/mindie_ref/mindie_llm/atb_models
```